

# WB XAI-2 PD2

Jakub Szypuła

01/04/2021

Słowem wstępu chciałbym zauważyć, że w poprzedniej pracy domowej wykorzystywałem inną wersję tego samego zbioru, która leżała u mnie na dysku z zeszłego roku. Teraz używam tej “oficjalnej” i zamiast klas 0/1 jest bad/good, co oczywiście niesie za sobą taki skutek, że klasy są zamienione miejscami przy predykcji (bo b jest przed g w alfabecie).

## Przewidywanie obserwacji

```
predict(model, gcd[1,])$predictions
```

```
##           bad           good  
## [1,] 0.1113913 0.8886087
```

```
gcd[1, "class"]
```

```
## [1] good  
## Levels: bad good
```

Jak widać, model dobrze przewiduje klasę dla tej obserwacji.

## Dekompozycja obserwacji

```
lime_gcd1_mlr <- predict_surrogate(explainer = explainer,  
                                   new_observation = gcd[1, -21],  
                                   n_features = 5,  
                                   n_permutations = 1000,  
                                   type = "lime")
```

```
## Warning: num_dependents does not contain enough variance to use quantile  
## binning. Using standard binning instead.
```

```
## Warning in gower_work(x = x, y = y, pair_x = pair_x, pair_y = pair_y, n =  
## NULL, : skipping variable with zero or non-finite range
```

```
plot(lime_gcd1_mlr)
```



Zauważamy tutaj, że bycie pod kreską znacznie obniża szanse na bycie dobrym kredytobiorcą, pokrywa się to z obserwacjami z poprzedniej PD1. Krótki kredyt, brak innych payment plans, brak znanych oszczędności i najbardziej wartościowa własność będąca nieruchomością wpływają pozytywnie na ocenę kredytobiorcy, znów, w zgodzie z tym co zostało ustalone na poprzedniej PD. Czyli ogólne wnioski jakie możemy wyciągnąć z grubsza się zgadzają.

## Dekompozycja dla różnych obserwacji

Obserwacja numer 201 (wartość poprawna: good, wartość przewidziana: good)

```
lime_gcd2_mlr <- predict_surrogate(explainer = explainer,
                                   new_observation = gcd[201, -21],
                                   n_features = 5,
                                   n_permutations = 1000,
                                   type = "lime")
```

```
## Warning: num_dependents does not contain enough variance to use quantile
## binning. Using standard binning instead.
```

```
## Warning in gower_work(x = x, y = y, pair_x = pair_x, pair_y = pair_y, n =
## NULL, : skipping variable with zero or non-finite range
```

```
plot(lime_gcd2_mlr)
```



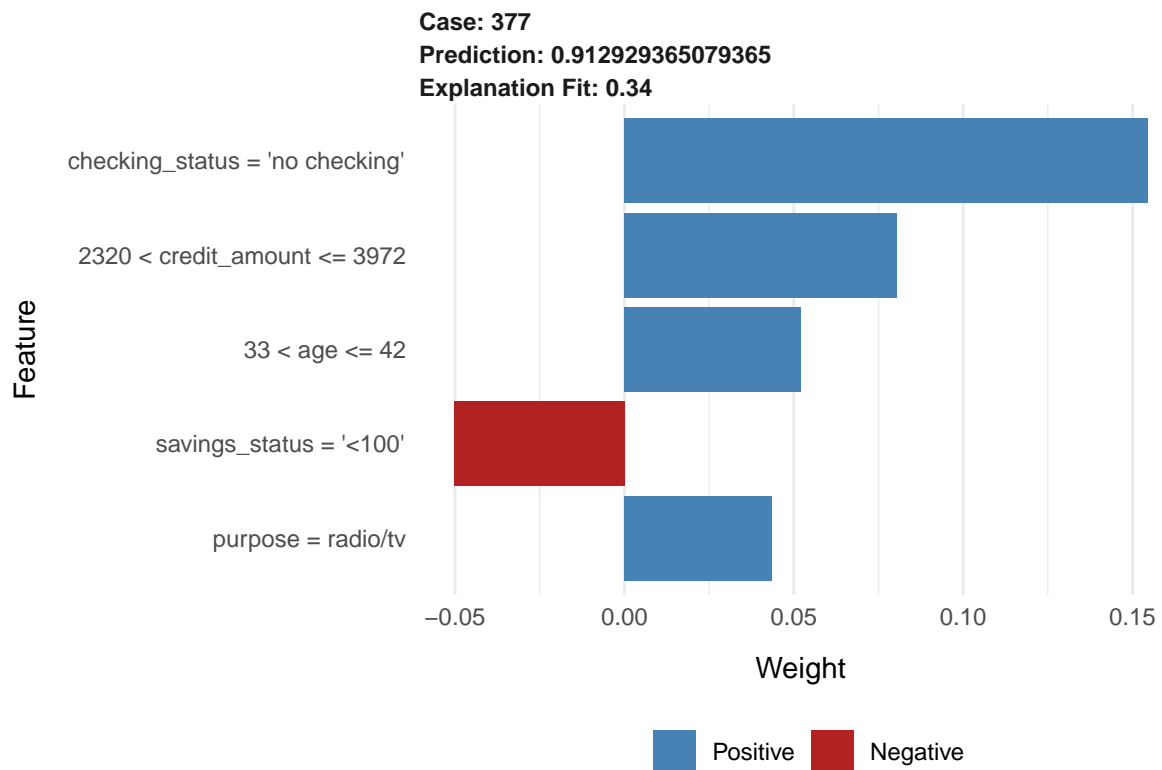
Obserwacja numer 377 (wartość poprawna: good, wartość przewidziana: good)

```
lime_gcd3_mlr <- predict_surrogate(explainer = explainer,
                                   new_observation = gcd[377, -21],
                                   n_features = 5,
                                   n_permutations = 1000,
                                   type = "lime")
```

```
## Warning: num_dependents does not contain enough variance to use quantile
## binning. Using standard binning instead.
```

```
## Warning in gower_work(x = x, y = y, pair_x = pair_x, pair_y = pair_y, n =
## NULL, : skipping variable with zero or non-finite range
```

```
plot(lime_gcd3_mlr)
```



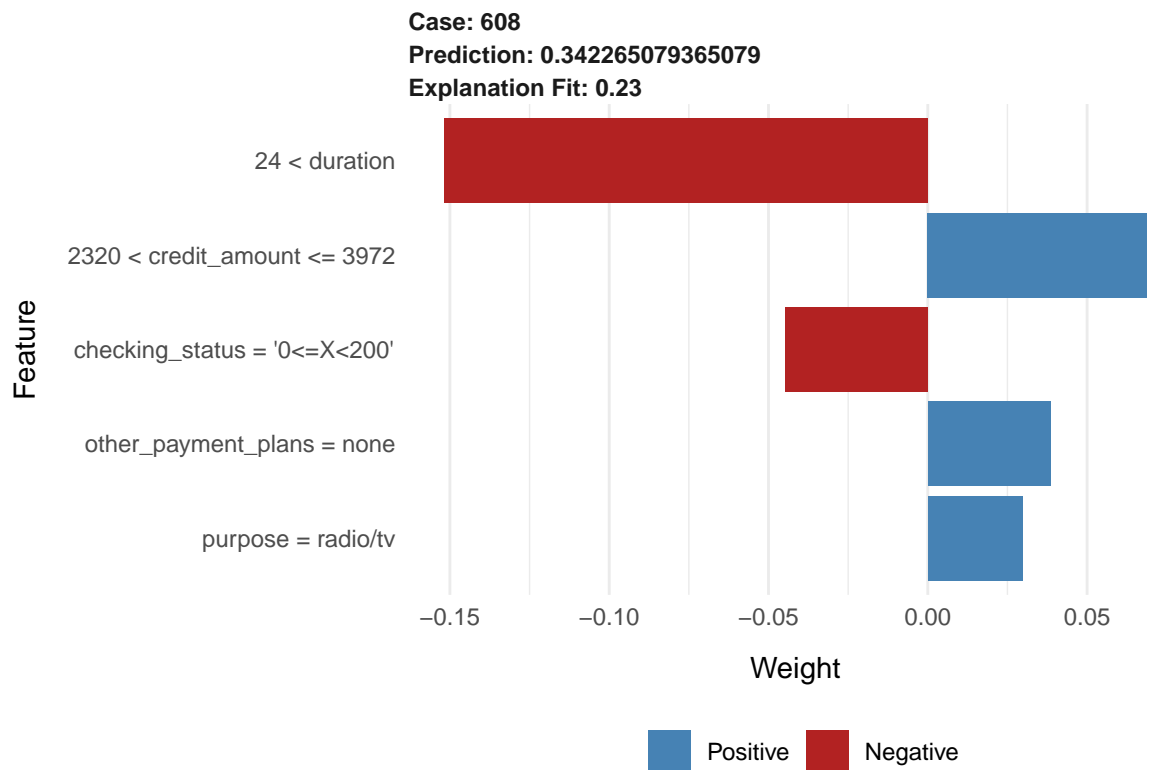
Obserwacja numer 608 (wartość poprawna: bad, wartość przewidziana: bad)

```
lime_gcd4_mlr <- predict_surrogate(explainer = explainer,
                                   new_observation = gcd[608, -21],
                                   n_features = 5,
                                   n_permutations = 1000,
                                   type = "lime")
```

```
## Warning: num_dependents does not contain enough variance to use quantile
## binning. Using standard binning instead.
```

```
## Warning in gower_work(x = x, y = y, pair_x = pair_x, pair_y = pair_y, n =
## NULL, : skipping variable with zero or non-finite range
```

```
plot(lime_gcd4_mlr)
```




Obserwacja numer 797 (wartość poprawna: bad, wartość przewidziana: bad)

```
lime_gcd5_mlr <- predict_surrogate(explainer = explainer,  
                                   new_observation = gcd[797, -21],  
                                   n_features = 5,  
                                   n_permutations = 1000,  
                                   type = "lime")
```

```
## Warning: num_dependents does not contain enough variance to use quantile  
## binning. Using standard binning instead.
```

```
plot(lime_gcd5_mlr)
```



Dla różnych obserwacji zmieniają się najistotniejsze zmienne, nawet bardziej niż w wypadku PD1. Jednak poza tym dla tych samych wartości danych zmiennych wpływy mają ten sam znak, a nawet podobne wartości. Jeśli zwrócimy uwagę, to zauważymy też, że dla ujemnego `checking_status` wpływ jest mocno negatywny, dla między 0 a 200 jest lekko negatywny, a dla `no checking` jest znacząco pozytywny. Wygląda to jakby wzrost wpływu był zależny od wzrostu tej wartości (jeżeli potraktujemy `no checking` jako max). Podobne wartości możemy zauważyć przy wieku, `duration` i `credit_amount` (choć przy dwóch ostatnich to mniejsze wartości są lepsze).

Więc w tym zbiorze, także na podstawie PD1 przy pytaniu “jaka zmienna jest najważniejsza” możemy powiedzieć “to zależy”. Nie jest to konieczne problem, np. w *papier-kamień-nożyce* nie ma zagrania, które zawsze wygrywa. Przy 20 zmiennych objaśniających jednak zbiór ten nie jest na poziomie tej prostej gry, a raczej na poziomie np. marki *Age of Empires™*

## Porównanie z shap

```
pp_ranger_shap_gcd_1 <- predict_parts(explainer, new_observation = gcd[797, -21], type = "shap", B = 10,
plot(pp_ranger_shap_gcd_1)
```



Dla obu metod różne są najważniejsze zmienne, co ciekawe też zmienna **personal\_status** dla obu metod ma różny wpływ (słaby pozytywny vs minimalnie negatywny). Można z tego wysnuć wniosek, że metody zgodne są co do tego czy “ważne” zmienne są pozytywne, czy negatywne, zaś przy mniej ważnych zaczynają się nie zgadzać co do skali wpływu szczegółów a nawet tego, czy te szczegóły dają wkład na plus, czy na minus.

Filozoficznie można powiedzieć, że są w tym zachowaniu podobne do ludzi.